

CENTRO UNIVERSITÁRIO DE BRASÍLIA – CEUB

RELATÓRIO FINAL

Projeto Prático – Desenvolvimento para Ciência
de Dados II

Construção de um Data Warehouse e Aplicação de Machine Learning sobre Dados de Vendas

Aluno: Artur Nemer Xavier Costa

Professor: José Antônio de Paiva Júnior

1. Introdução

Este relatório apresenta o desenvolvimento de uma solução completa de Business Intelligence, contemplando a modelagem dimensional dos dados, a implementação de um Data Warehouse em PostgreSQL, a realização de análises exploratórias e a aplicação de algoritmos de Machine Learning. O objetivo foi transformar dados operacionais em informações estratégicas para apoiar a tomada de decisão.

2. Objetivos

Objetivo Geral

Desenvolver um ambiente analítico capaz de armazenar, organizar e analisar dados de vendas utilizando PostgreSQL e Python.

Objetivos Específicos

- Construir um Data Warehouse em Star Schema.
- Implementar um processo ETL.
- Desenvolver consultas analíticas.
- Realizar análise exploratória dos dados.
- Aplicar algoritmos de classificação e regressão.
- Comparar modelos e gerar insights.

3. Dataset

Foi utilizado o conjunto de dados público Sample Superstore, contendo 9.994 registros e 21 atributos relacionados a pedidos, clientes, produtos, regiões, categorias, vendas, descontos, quantidades e lucro.

4. Modelagem Dimensional

O Data Warehouse foi estruturado utilizando o modelo Star Schema, composto pela tabela fato FATO_VENDAS e pelas dimensões DIM_CLIENTE, DIM_PRODUTO, DIM_LOCAL e DIM_TEMPO. A tabela fato concentra as métricas de vendas, enquanto as dimensões armazenam os atributos descritivos necessários às análises.

5. Implementação

A implementação foi realizada em PostgreSQL, com criação das tabelas, processo ETL em Python para carga dos dados, criação de views analíticas e integração entre o banco de dados e as bibliotecas de Ciência de Dados.

6. Análise Exploratória

Foram desenvolvidos gráficos para avaliar a distribuição das vendas, lucro por categoria, evolução temporal das vendas, vendas por região e lucro por segmento.

Também foi calculada a matriz de correlação entre as variáveis numéricas.

7. Machine Learning

Foram implementados os algoritmos K-Nearest Neighbors (KNN), Árvore de Decisão, Random Forest, Regressão Logística e Regressão Linear. A avaliação utilizou Accuracy, Precision, Recall, F1-Score, Matriz de Confusão, MAE, MSE, RMSE e R^2 .

8. Resultados

A comparação dos modelos permitiu identificar aquele com melhor desempenho para o conjunto de dados analisado. O processo evidenciou a importância da preparação dos dados e da seleção adequada dos atributos para obtenção de resultados consistentes.

9. Insights de Negócio

Os resultados indicam que a categoria Technology apresenta elevada lucratividade; as regiões West e East concentram maior volume de vendas; descontos elevados reduzem significativamente o lucro; clientes do segmento Corporate apresentam maior ticket médio; e o aumento da quantidade vendida tende a elevar o valor total das vendas.

10. Conclusão

O projeto integrou conceitos de Banco de Dados, Engenharia de Dados, Business Intelligence e Machine Learning em uma solução única. A implementação demonstrou como a organização dos dados em um Data Warehouse, aliada a técnicas de aprendizado de máquina, contribui para a geração de conhecimento e suporte à tomada de decisão.

11. Tecnologias Utilizadas

Python, Pandas, NumPy, Matplotlib, Scikit-learn, SQLAlchemy, PostgreSQL e Visual Studio Code.

12. Referências

Kimball, R. The Data Warehouse Toolkit.

Documentação oficial do PostgreSQL.

Documentação oficial do Pandas.

Documentação oficial do Scikit-learn.

Sample Superstore Dataset.